

# 物理合格性考试试题难度影响因素的实证研究

冯雪媚 张 殷

**[摘 要]** 在大规模教育考试中,难度是试题质量评估中一个重要的指标。本文以物理合格性考试试题为研究对象,首先基于文献和调查等多方面研究,初步提出影响物理合格性考试选择题试题难度的 10 条假设,开发了具有可操作性且效度良好的试题难度评估工具,并应用于 2014—2019 年广西高中物理合格性考试的 108 道单项选择题。其次,结合偏相关分析、非参数均值秩检验等统计方法进行统计检验和量化分析,得到了与选择题难度密切相关的 5 个因素。最后,运用多元逐步回归的方法得到物理合格性考试选择题难度系数  $P$  的预估模型,利用 2020 年物理合格性考试数据来检验模型的可靠性,经检验,该模型预估效果良好,也证实了数据分析的可靠性。

**[关 键 词]** 合格性考试;物理试题;难度影响因素;难度预估

---

作者简介:冯雪媚,东莞市塘厦初级中学教师,硕士,研究方向为物理教育测评。张殷,本文通讯作者,广西师范大学副教授,博士,硕士生导师,研究方向为科学教育测评。

基金项目:2021 年度国家教育考试科研规划课题“基于学科核心素养的情境化开放性试题的开发和质量评估研究”(GJK2021023)成果。

说明:本文系“2022 教育考试研讨会”征文。

在任何一项大规模考试当中,难度是评估试题质量极为重要的参数之一。著名教育测量学家斯滕纳(Stenner)曾说过,如果你不知道这个问题为什么比那个问题难,那么你就不知道你在测量什么。他的陈述表明,只有保证任务的结构效度是有效的,传统上信效度的统计才会有意义<sup>①</sup>。在大规模教育考试中,试题的难度不单是一个科学问题,更是非常敏感的社会问题,它被赋予的社会价值远大于测量学价值,受到社会的广泛关注。因此,实现对试题难度准确把控的重要性不言而喻。对提高大规模教育考试命题质量而言,重要的是在命题阶段就能够比较准确地预测试题的难度值。我国大规模教育考试牵涉高利害性利益,没有考前试测的环境,事后标定试题难度显然不符合当前的实况,所以事前准确把控试题的难度就尤为重要。

试题难度影响因素就是影响学生正确作答,阻碍问题解决过程中思维前进的因素。试题难度受主客体影响,主体主要指被试对象的水平,如智能水平、知识掌握程度、思维习惯等;客体方面主要从试题角度而言,如知识点数、知识点综合程度、阅读量、问题表达、条件充要等。本文研究的被试群体是2014—2019年参与广西壮族自治区物理学考的高二年级学生,考生人数达到30多万,考生样本量庞大,可认为被试群体的能力、状态、情绪等主体因素较为稳定。研究通过控制被试个体的主观变量,探讨试题难度的客观变量,运用统计方法和工具基于广西全区30多万考生的实考数据来探寻影响试题难度因素及其权重,试图摸清试题内部结构与难度之间的关联性,从而建立预估模型,以实现对试题难度较为精准的把控。

## 一、研究设计

### (一) 研究思路

本研究的总体思路是:首先,在研读大量文献和调查的基础上,提出影响试题难度因素

---

<sup>①</sup> Fisher-Hoch H, Hughes S. What makes mathematics exam questions difficult [R]. British Educational Research Association, 1996:66.

的假设;其次,建立测量工具,即各因素量化标准,利用相关分析、非参数均值检验等统计方法对各影响因素进行统计分析,得出影响试题难度因素;最后,利用这些影响因素建立预估模型并对其加以检验。

## 二) 研究对象

合格性考试是普通高中学业水平考试的重要组成部分,是衡量学生达到国家规定学习要求程度的手段。所以本研究以 2014—2019 年广西高中物理合格性考试的 108 道单项选择题作为研究对象。

## 三) 统计方法

本研究采用偏相关分析、非参数均值检验和回归分析等统计方法来分析检验各因素,利用获得的客观统计数据来推断结论。

## 四) 物理试题难度的影响因素

确立试题难度影响因素是试题难度评估的首要工作。不同的研究者价值出发点不同,所以研究取向也会有所区别。教育工作者根据实践经验总结了很多影响物理试题难度的因素,对问题难度的认识比较具体;心理学领域的研究者多从一般问题角度出发开展研究,如国外学者伯恩霍尔特(Bernholt)和帕尔希曼(Parchmann)根据任务的复杂度将化学学习的任务框架设计为 5 个层级,分别为日常经验、事实、过程、线性因果关系和多变量相关关系。他们发现结果能够较大程度预测任务表现,说明基于任务需求法来确定任务难度的过程既可为测试能力结构提供调整的依据<sup>①</sup>,也能够极大程度预测任务难度的大小<sup>②③</sup>。教育工作

① Bernholt S, Parchmann I. Assessing the complexity of students' knowledge in chemistry [J]. Chemistry Education Research & Practice, 2011, 12(2):167-173.

② Robinson P. Task complexity, task difficulty, and task production: exploring interactions in a componential framework [J]. Applied Linguistics, 2001, 22(1):27-57.

③ 张丽,辛自强.平衡任务复杂性的事前与事后分析[J].心理发展与教育,2008(02):46-53.

者结合自身实践经验,从一般的试题难度到具体学科的试题难度,总结了许多有益的经验。新加坡研究者成(Cheng)教授提出影响试题难度的因素主要来自以下三个方面:内容难度、刺激难度、任务难度<sup>①</sup>。本研究结合对相关文献的梳理与分析,以及学科本身的独特性,将物理试题难度来源分为内部刺激和外部刺激,如表1所示。

表1 物理试题难度影响因素的来源

| 维度(难度来源)                     | 难度因素                                                                                                                                     |
|------------------------------|------------------------------------------------------------------------------------------------------------------------------------------|
| 内部刺激难度:考查被试个体的知识、能力、技能、思维品质等 | 知识(知识深广度、知识点在教学中的地位/是否受重视);<br>能力(认知复杂性、建模复杂性、数学运算与技能复杂性、推理复杂性、证据获取复杂性……);<br>思维(思维发散性、思维复杂性……)                                          |
| 外部刺激难度:试题的文字组织、呈现方式、提供的信息等   | 阅读量、试题呈现关键信息;<br>情境或背景材料与学生的熟悉程度;<br>题型,信息呈现方式有无示意图、表格等;<br>问题的表达方式,问题目标的开放性,分步设问情况,阶梯性;<br>猜答得分的概率、可猜度、猜答度;<br>信息的干扰性、隐蔽性、歧义度、不透明性、模糊度等 |

本研究结合文献研究和调查结果分析提出影响物理合格性考试试题难度的因素分别有知识点数、阅读量、情境熟悉程度、情境结合程度、建模、推理、数学、图表、认知水平和提示度。具体阐述如下。

基于认知负荷理论,斯威勒(Sweller)认为总的认知负荷包括内部认知负荷、外部认知负荷和关联认知负荷。内部认知负荷与学习任务本身的属性有关,如果学习任务或者考查知识容量较多,就会造成“信息超载”,超出学习个体所承受的认知负荷,学习效果也会大打折扣<sup>②</sup>。所以本研究提出的假设是知识点数越多,物理问题难度越大。

物理合格性考试试题虽然会辅以图表来考查学生的能力,但仍然以文字叙述为主。从

<sup>①</sup> Cheng T S. On varying the difficulty of test items [R/OL]. A paper presented at the 32nd Annual Conference of the Interactional Association for Educational Assessment, Singapore, May 2006[2006-09-16]. <http://www.iaea2006.seab.gov.sg/conferencel>.

<sup>②</sup> 查先进,黄程松,严亚兰,等.国外认知负荷理论应用研究进展[J].情报学报,2020,39(05):547-556.

信息加工的角度来看,问题呈现的信息越多,理解问题陈述的过程中产生的负荷就越大<sup>①</sup>。再者,学生在访谈中也谈到,对于“长长”的题目,会产生一定的心理负担,有一定的畏难情绪。

《普通高中物理课程标准(2017 年版 2020 年修订)》的命题建议指出,根据物理学科核心素养的水平层次、知识要求的深度或广度、试题情境的复杂性或新颖性等多方面来设计试题的难度<sup>②</sup>。由新课标可知,情境不仅是甄别学生核心素养的依据也是设置考试难度梯度的重要依据。情境本身就是一个复杂的参数,到底情境是如何影响试题难度的呢?如果物理问题的情境是考生经历过或者体验过的,考生就有可能从已有的认知结构中提取相应的图式,由已知到未知,从而顺利地解决问题。问题情境常常源于生产生活或科研科技等,这些具体的情境与抽象的物理情境之间往往有一定的差距,若被试个体找不到它们之间的本质关联就会无从下笔。因此,情境越新颖或情境对于学生越陌生,则试题难度越高。

现研究者关于试题难度的实证研究在情境维度上主要集中于情境新颖度上,而情境的其他角度鲜有实证研究。情境的关联性指向问题情境设置,有研究者用情境与问题结合紧密程度来衡量情境与问题关联性的强弱。在本学科上,情境与试题结合程度越紧密,物理问题就隐藏得越深,对学生解决问题能力的要求则越高。

物理任务对能力的考查总是既定于某个情境之中,被试个体首先要从情境中提取关键的物理信息,并对其抽象、简化为物理模型,然后利用模型去证明、解释和预测结果,在这个过程中物理建模发挥了关键的作用。本研究认为建模水平要求越高,则试题难度越大。

科学推理是物理核心素养一个重要的组成部分。物理解题过程往往会对应着一个推理过程。科学推理水平反映了学生解决问题时思维链的长短。若问题能在一步或两步内被解答,则此问题相对容易;从已知到未知,需要被试个体从复杂的题目中抽丝剥茧,一环扣一环

① 陈燕,王祖浩. 高考实验题“绝对难度”评估工具的研究[J]. 全球教育展望,2013,42(02):45-53.

② 中华人民共和国教育部. 普通高中物理课程标准(2017 年版 2020 年修订)[M]. 北京:人民教育出版社,2020:63.

地推理,这个过程步骤越多,则思维出错的可能性就越大,就像从一个地方出发到另一个地方,行走的路线中分支越多,就越易走错。这种情况就会要求学生的逻辑推理思维能力更强,问题复杂了,试题的难度也增加了。

数学运算是解决物理问题不可忽视的因素。物理问题的解决需要数学工具辅助,大量的物理规律和物理概念需要用数学手段去描述,数理是一个有机的整体。本研究从数学运算及数学技能两方面来衡量数学因素。若解答试题所需要用到的数学运算量越大、数学技能越复杂,则试题难度越大。

非连续文本又称间断性文本,它来源于国际学生评估项目(PISA)测试,是以间断性内容信息符号所组成的一组综合性阅读文本<sup>①</sup>。它区别于由逻辑或语感严密的字词句段落结构层次构成的连续性文本,是以间断性的内容信息符号所组成的一种综合性阅读文本。在物理学科中,主要是图(表)文结合的方式。如  $v-t$  图、波形图、示意图等。从物理的视角来看,图表语言也是物理重要内容之一。图表使得物理表达更加简洁,但同时也可能隐藏着重要的物理信息。学会从非连续性文本中筛选、整合,获取关键的信息,得出正确的结论,也是物理考查的重要内容之一。

布卢姆教育目标分类将认知过程分为6个内容,分别是:记忆/回忆(remember)、理解(understand)、应用(apply)、分析(analyze)、评价(evaluate)、创造(create)<sup>②</sup>。有研究者认为布卢姆教育目标分类下的理解、应用、分析、评价和创造对应高阶思维能力的要素<sup>③</sup>。从试题视角来看,认知水平体现的是对知识内容的考查要求,也是对问题考查的能力思维要求。所以,随着知识考查认知层次的提高,试题难度也在增大。

教育部考试中心研究者提到试卷的卷面描述对试题的解答所提供的启发性信息的多寡

---

① 程淑贞,裴羽霄. 高考中一个值得关注的倾向:非连续性文本的考查[J]. 教育理论与实践,2015,35(17):18-21.

② (美)安德森,等. 布卢姆教育目标分类学:分类学视野下的学与教及其测评[M]. 蒋小平,张琴美,罗晶晶,译. 北京:外语教学与研究出版社,2009:51-52.

③ 汪茂华. 高阶思维能力评价研究[D]. 上海:华东师范大学,2018:227.

会影响试题的难易程度<sup>①</sup>。在题目的表述中,有些地方可能会包含一些对被试个体解题有利的信息,这些信息会对考生解题起到提示作用或者被试个体可以借助选择题的选项找到答案,从而跳过命题者设置的关卡(或者利用生活经验跳过命题者的关卡),这样就降低了试题的难度。

## 二、研究结果

### (一) 影响因素量化标准

通过对上述各因素的分析,本文初步提出影响物理合格性考试选择题试题难度的 10 条假设,并确定了各个因素的量化赋值标准,如表 2 所示。

表 2 物理合格性考试选择题影响因素量化标准

| 因素     | 量化标准/赋值标准                                                                                                                                    |
|--------|----------------------------------------------------------------------------------------------------------------------------------------------|
| 建模     | 以物理学业标准科学思维素养的建模水平为划分依据:<br>0——能识别一些简单的物理模型或能在熟悉的问题情境中应用常见的物理模型<br>1——能在熟悉的问题情境中根据需要选用恰当的模型解决简单的物理问题<br>2——能将实际问题中的对象和过程转换成物理模型              |
| 情境熟悉程度 | 根据试题所创设的问题情境与学生认知的远近程度划分为 2 个水平:<br>0——熟悉情境或者没有情境<br>1——陌生情境(例如以当代中国的重大科技成果为情境)                                                              |
| 阅读量    | 以题目中文字表达的字符数来衡量(单位:字符数)                                                                                                                      |
| 提示度    | 试题可能隐含着一些对被试解题有帮助的信息,这些信息对考生解题起到了提示作用,根据是否有提示划分为 2 个水平:<br>0——可以通过借助选项找到答案,从而跳过命题者设置的关卡(或者利用生活经验跳过命题者的关卡),这样就降低了试题的难度<br>1——无法借助选项跳过命题者设置的关卡 |
| 认知水平   | 参照《普通高中物理课程标准(实验)》对于认知水平的划分,可分为 4 个水平:<br>1——了解      2——认识      3——理解      4——应用                                                             |

① 杜明荣. 高中物理试题难度的影响因素研究[D]. 重庆:西南大学,2008:18.

续表

| 因素        | 量化标准/赋值标准                                                                                                                                                                                                               |
|-----------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 图表        | 1——有图像,模拟图或者简化图,试题的已知条件已经在文字部分进行了充分的说明,图形或表格只起到形象表达和辅助说明的作用<br>2——部分条件隐含在图表中并未在题干中说明,解题条件需要读图得出                                                                                                                         |
| 推理<br>广度  | 推理广度以完成任务所需的逻辑推理转折数来衡量:<br>0——0个推理数  1——1个推理数  ……                                                                                                                                                                       |
| 数学<br>复杂性 | 根据数学运算与技能的复杂程度可划分为3个水平:<br>1——不需要数学运算与技能或者仅需要小学以内的加减乘除运算,口算就可以基本解决<br>2——简单数值运算与基本技能(包括少量字母符号)。简单的数值运算指的是分数、比例运算;基本技能包括单位、计数换算<br>3——复杂符号运算、复杂数值计算、复杂的方程求解、三角函数等                                                        |
| 情境结合程度    | 根据情境背景信息与问题紧密结合程度可划分为3个水平:<br>1——情境分离型:去掉提供的情境材料,仍能作答出考查内容,两者无直接关系<br>2——情境嵌入型:情境材料和考查内容相互融合,情境在问题解决中起到装饰作用,情境信息不是解题关键条件,套用相关模板或依靠知识储备也可作答(情境信息属于次要信息)<br>3——情境结合型:情境信息是解题关键必要条件,考查内容及知识点需要从情境材料中提取,无情境信息则作答条件不足,完全无法作答 |
| 知识量       | 以课程标准列出的知识点为标准:<br>1——1个知识点  2——2个知识点  ……                                                                                                                                                                               |

（二）量化标准的信度检验

建立好量化工具首先需要对其进行信度的检验。随机从108道试题中抽取一道选择题,并请5位人员(1位物理教育博士、3位物理在职教师、1位物理教育与测量研究方向的研究生)按照上文确立的赋值标准对选取的这道试题进行赋值。5位人员在量化赋值上的肯德尔和谐系数和显著性水平分别为0.922和0.000。因此本研究提出的影响因素量化标准具有可靠性和稳定性。接下来按照本研究建立的因素量化标准,对108道选择题的每一题进行因素分析并赋值,以获取统计的数据。

（三）试题难度影响因素的量化分析

本研究利用建立的评估工具,对108道选择题的10个因素赋值,各个影响因素水平描述统计如表3所示。



表 3 选择题各影响因素水平描述统计结果

| 因素   | 水平        | 计数 | 占比(%)  | 因素     | 水平 | 计数 | 占比(%)  |
|------|-----------|----|--------|--------|----|----|--------|
| 提示度  | 0         | 97 | 89.81% | 情境熟悉程度 | 0  | 96 | 88.90% |
|      | 1         | 11 | 10.19% |        | 1  | 12 | 11.10% |
| 建模   | 0         | 97 | 89.80% | 数学     | 1  | 98 | 90.74% |
|      | 1         | 10 | 9.30%  |        | 2  | 6  | 5.56%  |
|      | 2         | 1  | 0.90%  |        | 3  | 4  | 3.70%  |
| 推理广度 | 0         | 90 | 83.33% | 情境结合程度 | 1  | 58 | 53.70% |
|      | 1         | 12 | 11.11% |        | 2  | 10 | 9.26%  |
|      | 2         | 6  | 5.56%  |        | 3  | 40 | 37.04% |
| 认知水平 | 1         | 12 | 11.11% | 知识量    | 1  | 93 | 86.11% |
|      | 2         | 44 | 40.74% |        | 2  | 14 | 12.96% |
|      | 3         | 43 | 39.81% |        | 3  | 1  | 0.93%  |
|      | 4         | 9  | 8.33%  | 图表     | 1  | 76 | 70.37% |
| 阅读量  | 平均 74 个字符 |    |        |        | 2  | 32 | 29.63% |

1. 各因素与难度间的线性相关性分析

首先做偏相关分析,即在控制其他变量的线性影响的条件下分析各因素与难度间的线性相关性,其统计结果如表 4 所示。

表 4 选择题十因素偏相关系数

| 影响因素  |       | 建模    | 情境熟悉程度 | 阅读    | 提示度    | 认知水平  | 图表    | 推理广度   | 数学    | 情境结合程度 | 知识数量  |
|-------|-------|-------|--------|-------|--------|-------|-------|--------|-------|--------|-------|
| 偏相关分析 | 偏相关系数 | 0.339 | 0.286  | 0.120 | -0.428 | 0.699 | 0.152 | -0.026 | 0.225 | -0.212 | 0.159 |
|       | 显著性   | 0.001 | 0.004  | 0.237 | 0.000  | 0.000 | 0.133 | 0.796  | 0.025 | 0.035  | 0.555 |

通过偏相关分析,探寻在统计意义上对试题难度具有显著影响的因素,由表 4 可知,建模、情境熟悉程度、提示度、认识水平、数学和情境结合程度的显著性水平  $p$  均小于 0.05。认知水平因素与试题难度  $(1-p)$  具有较高相关性。其次是提示度、建模、情境熟悉程度、数学,这与本研究的预期假设相吻合。阅读量、图表、推理广度、情境结合程度和知识量几乎与难度  $(1-p)$  不相关,甚至是负相关。阅读量因素与试题难度  $(1-p)$  并不相关,原因可能是合格考的选择题比较简单,情境相对简单,“简洁明了”也是大规模考试试题的一个基本要求,试题几乎不会出现冗余的信息来增加学生的阅读负担。阅读量在一

个较为合理范围,都不会引起学生认知困难,故本研究认为阅读量因素并不影响物理合格考试题的难度。

原假设中认为若部分条件隐含在图表中并未在题干中说明,需要从图表中提取关键信息,会导致试题难度的增加,但统计结果显示两者并无关联。原因是物理合格考中大部分题目配对了辅助性的图,且解题条件在题干中已经描述清楚,除了个别题干出现较为常见的  $v-t$  函数图象。结合学生问卷调查,也有学生提到,图表的复杂度会增加认知的困难,但是这里学生认为的图一般指的是电磁学中磁场、电场的复杂图。

推理数量的多寡与试题难度( $1-p$ )没有显著相关,主要原因是物理合格考的推理较为简单,推理步骤少,推理类型多数是因果推理,所以物理过程较为简单,不涉及过多的转折,都属于低水平的推理,比如根据自由落体运动公式,推理得到末速度,这种仅涉及较为短的思维链,并不会造成学生认知负担,这对于绝大部分考生都是可接受的。所以本研究认为推理广度因素对试题的难度没有影响。

情境的结合程度并未显著影响试题难度值( $1-p$ ),其中很大原因是物理合格考试题中的情境是学生较为熟悉的或者是抽象的理论情境材料,并非像 PISA 中接近生活实际的情境材料,却对学生的迁移能力、综合应用能力要求极高。物理合格考中类似于时间、时刻、位移、路程这样的生活情境,与试题结合程度虽高,但是学生对此太熟悉了,并且都能从情境中成功提取相关的信息,所以本研究认为这一因素并未显著影响试题难度,应舍去。

知识数量增加并不会显著影响试题难度,原因是试题中即使考查了较多的知识点,但是这些考查的知识均属于了解、认识等低层次的认知水平,对试题难度的影响也许还远远不及一个高认知水平的知识,这和前人的很多结论有共通之处,即量化因素的影响程度远不及质性因素。所以本研究认为知识量不会影响试题难度,应舍去。

## 2. 各因素不同水平的差异性分析

接着利用非参数均值秩检验来检验各因素不同水平的差异性。一般来说,如果某个影响因素确实存在,那么其不同水平之间应该存在比较明显的差异。本研究的样本数据不服从正态分布,因此不宜采用方差分析和  $t$  检验。像“建模”“认知水平”这类多个独立样本的

因素采用非参数多样本克鲁斯卡尔-沃利斯检验(Kruskal-Wallis Test);两个独立样本采用曼-惠特尼 U(Mann-Whitney U)检验,例如“提示度”“图表”这些因素。非参数秩检验统计结果如表 5 和表 6 所示。

表 5 克鲁斯卡尔-沃利斯 H(K)检验综合表

| 因素     | 水平 | 秩平均值   | 克鲁斯卡尔-沃利斯 H(K) | 自由度 | 渐近显著性 |
|--------|----|--------|----------------|-----|-------|
| 建模     | 0  | 50.22  | 18.001         | 2   | 0.000 |
|        | 1  | 90.85  |                |     |       |
|        | 2  | 106.00 |                |     |       |
| 认知水平   | 1  | 19.88  | 61.579         | 3   | 0.000 |
|        | 2  | 37.10  |                |     |       |
|        | 3  | 72.37  |                |     |       |
|        | 4  | 100.33 |                |     |       |
| 推理广度   | 0  | 49.24  | 16.975         | 2   | 0.000 |
|        | 1  | 73.96  |                |     |       |
|        | 2  | 94.50  |                |     |       |
| 数学     | 1  | 51.45  | 11.199         | 2   | 0.004 |
|        | 2  | 75.75  |                |     |       |
|        | 3  | 97.38  |                |     |       |
| 情境结合程度 | 1  | 55.05  | 5.552          | 2   | 0.062 |
|        | 2  | 74.65  |                |     |       |
|        | 3  | 48.66  |                |     |       |
| 知识数量   | 1  | 53.85  | 2.963          | 2   | 0.227 |
|        | 2  | 54.96  |                |     |       |
|        | 3  | 108.00 |                |     |       |

表 6 曼-惠特尼 U 检验综合表

| 因素     | 水平 | 秩平均值  | 曼-惠特尼 U | 威尔科克森 W  | Z      | 渐近显著性(双尾) |
|--------|----|-------|---------|----------|--------|-----------|
| 情境熟悉程度 | 0  | 52.70 | 403.500 | 5059.500 | -1.687 | 0.092     |
|        | 1  | 68.88 |         |          |        |           |
| 提示度    | 0  | 59.15 | 82.500  | 148.500  | -4.584 | 0.000     |
|        | 1  | 13.50 |         |          |        |           |
| 图表     | 0  | 51.27 | 970.500 | 3896.500 | -1.653 | 0.098     |
|        | 1  | 62.17 |         |          |        |           |

由表5和表6可知,与试题难度具有显著性相关的5个因素(认知水平、提示度、建模、情境熟悉程度和数学)的显著性水平均小于0.05,秩平均值随着各因素水平的提高而增大,所以这5个因素各水平的划分是合理的。

四) 预估模型的建立

结合上述的分析,在非参数均值秩检验中,具有统计意义的5个因素的秩平均值随着各因素水平的提高而增大,所以这5个因素与难度值(1 - p)大致呈线性关系。下面将采用多元回归分析建立预估模型,依次报告逐步回归法的各项分析结果。

1. 预估模型建立

由表7 预估模型的回归系数可知,在第5次形成模型拟合最好。判定系数 $R^2$ 是度量预估回归模型的拟合度,以此来判断该统计模型的解释力。整个模型复相关系数为0.860,判定系数 $R^2$ 为0.740,表示预测变量(认知水平、提示度、情境熟悉程度、建模和数学)能够解释因变量(试题难度1 - p)变异程度的74%,调整后的决断值也有0.727;德宾-沃森值接近2,通过了样本独立性检验。

表7 选择题预估模型的回归系数

| 模型摘要 <sup>[1]</sup>                |                      |       |            |         |        |
|------------------------------------|----------------------|-------|------------|---------|--------|
| 模型                                 | R                    | $R^2$ | 调整后的 $R^2$ | 标准估算的错误 | 德宾-沃森值 |
| 5                                  | 0.860 <sup>[e]</sup> | 0.740 | 0.727      | 0.08444 | 1.977  |
| a. 预测变量:(常量),认知水平                  |                      |       |            |         |        |
| b. 预测变量:(常量),认知水平,提示度              |                      |       |            |         |        |
| c. 预测变量:(常量),认知水平,提示度,情境熟悉程度       |                      |       |            |         |        |
| d. 预测变量:(常量),认知水平,提示度,情境熟悉程度,建模    |                      |       |            |         |        |
| e. 预测变量:(常量),认知水平,提示度,情境熟悉程度,建模,数学 |                      |       |            |         |        |
| f. 因变量:1 - p                       |                      |       |            |         |        |

方差分析(ANOVE)可以鉴定回归模型的显著性,由表8 复相关系数方差分析可知,该模型的复相关系数统计意义极其显著,显著性水平为0.000,小于0.05,回归模型是有意义的。

表 8 复相关系数方差分析

| ANOVA <sup>[a]</sup> |    |       |     |       |        |                      |
|----------------------|----|-------|-----|-------|--------|----------------------|
| 模型                   |    | 平方和   | 自由度 | 均方    | F      | 显著性                  |
| 5                    | 回归 | 2.066 | 5   | 0.413 | 57.954 | 0.000 <sup>[f]</sup> |
|                      | 残差 | 0.727 | 102 | 0.007 |        |                      |
|                      | 总计 | 2.793 | 107 |       |        |                      |

a. 因变量:  $1 - p$

f. 预测变量: (常量), 认知水平, 提示度, 情境熟悉程度, 建模, 数学

从表 9 预估模型回归系数可知,第 5 次形成回归模型中,引入的变量包括认知水平、提示度、情境熟悉程度、建模和数学,各因素回归系数均通过显著性检验,其中认知水平、情境熟悉程度、建模和数学因素显著正向影响因变量难度值( $1 - p$ ),提示度因素显著负向影响因变量试题难度值( $1 - p$ )。各因素的共线性数据的方差膨胀因子(variance inflation factor, VIF)小于 5 且接近 1。容差与 VIF 互为倒数,值均大于 0.1,且有 3 个变量接近 1,说明 5 个自变量之间不存在多重共线性。

表 9 预估模型回归系数

| 系数 <sup>[a]</sup> |        |          |        |          |       |        |        |        |       |       |
|-------------------|--------|----------|--------|----------|-------|--------|--------|--------|-------|-------|
| 模型                | 未标准化系数 |          | 标准化系数  | <i>t</i> | 显著性   | 相关性    |        |        | 共线性统计 |       |
|                   | B      | 标准<br>错误 | Beta   |          |       | 零阶     | 偏      | 部分     | 容差    | VIF   |
| (常量)              | -0.126 | 0.031    |        | -4.014   | 0.000 |        |        |        |       |       |
| 认知水平              | 0.121  | 0.011    | 0.598  | 10.596   | 0.000 | 0.753  | 0.724  | 0.535  | 0.801 | 1.248 |
| 提示度               | -0.152 | 0.027    | -0.285 | -5.545   | 0.000 | -0.375 | -0.481 | -0.280 | 0.965 | 1.036 |
| 情境熟悉程度            | 0.085  | 0.027    | 0.166  | 3.169    | 0.002 | 0.255  | 0.299  | 0.160  | 0.932 | 1.073 |
| 建模                | 0.082  | 0.026    | 0.174  | 3.136    | 0.002 | 0.479  | 0.297  | 0.158  | 0.826 | 1.211 |
| 数学                | 0.053  | 0.020    | 0.141  | 2.643    | 0.010 | 0.400  | 0.253  | 0.134  | 0.892 | 1.121 |

a. 因变量:  $1 - p$

由表 10 多重共线性诊断分析可知,条件指数均小于 10;方差比例和特征值也均符合统计上要求。

表 10 多重共线性诊断分析

| 共线性诊断 <sup>[a]</sup> |   |       |       |      |      |      |        |      |      |
|----------------------|---|-------|-------|------|------|------|--------|------|------|
| 模型                   | 维 | 特征值   | 条件指标  | 方差比例 |      |      |        |      |      |
|                      |   |       |       | (常量) | 认知水平 | 提示度  | 情境熟悉程度 | 建模   | 数学   |
| 5                    | 1 | 3.348 | 1.000 | 0.01 | 0.01 | 0.01 | 0.02   | 0.02 | 0.01 |
|                      | 2 | 1.025 | 1.807 | 0.00 | 0.00 | 0.38 | 0.08   | 0.32 | 0.00 |
|                      | 3 | 0.875 | 1.956 | 0.00 | 0.00 | 0.31 | 0.48   | 0.02 | 0.01 |
|                      | 4 | 0.630 | 2.305 | 0.00 | 0.00 | 0.27 | 0.42   | 0.55 | 0.00 |
|                      | 5 | 0.079 | 6.496 | 0.07 | 0.27 | 0.01 | 0.00   | 0.01 | 0.92 |
|                      | 6 | 0.042 | 8.927 | 0.92 | 0.72 | 0.02 | 0.00   | 0.09 | 0.06 |

a. 因变量: 1 - p

由图 1 可知,标准化的残差正态分布性良好。由图 2 可知,回归标准残差几乎都在  $p-p$  图的对角线上,两个图都说明了随机误差服从正态分布。




图 1 回归标准化残差直方图




图 2 回归标准化残差  $p-p$  图

综合以上的回归模型诊断分析,该回归模型统计意义极其显著,应该具有良好的预测效度,假设  $x_1$  = 认知水平;  $x_2$  = 提示度;  $x_3$  = 情境熟悉程度;  $x_4$  = 建模;  $x_5$  = 数学。

那么得出自变量和因变量之间的回归方程式是：

$$1 - p = -0.126 + 0.121x_1 - 0.152x_2 + 0.085x_3 + 0.082x_4 + 0.053x_5,$$

由此得到选择题难度系数  $p$  的预估模型:

$$p = 1 + 0.126 - 0.121x_1 + 0.152x_2 - 0.085x_3 - 0.082x_4 - 0.053x_5$$

## 2. 预估效度检验

预估效度可以通过比较回归模型计算出的理论预估值和实测值之间的拟合程度来检验。本研究选定 2020 年广西高中物理学业水平考试的所有单项选择题,共计 17 道,先用回归模型预估试题的难度值  $p$ ,接着检验它与实际测试结果的一致程度。预估与实测的难度值  $p$  对比如图 3 所示。




图 3 2020 年广西高中物理学业考选择题预估与实测数据对比

利用回归模型得到的预估值与实测值做相关分析,两者的皮尔逊相关系数  $R = 0.634^{**}$ ,显著性水平为 0.006,统计意义显著,这表明预测值与实测值的相关性很强。

综上,以认知水平、提示度、建模、情境熟悉程度、数学 5 个因素建立的回归模型具有良好的预测效果。

利用本研究得到的显著性影响试题的难度因素和选择题难度预估模型,可以为命题者实现对试题难度的有效调控与准确把握提供有意义的参考;构建试题难度评估工具和预估模型的研究方法与研究结论可以沿用于物理科目的选择性考试或者其他性质的考试,通过对影响因素和模型参数进行动态调整,可以提供一个较为准确的预估参考值。

(本研究得到广西招生考试院的支持,其提供并允许使用相关数据。特此鸣谢!)

# An Empirical Study on the Factors Affecting the Difficulty Level of Physics Test Items in the High School Academic Qualifying Examination

Xuemei FENG   Yin ZHANG

**Abstract:** In the large-scale educational examination, the difficulty level is an essential index in the quality evaluation of the test items. This study takes the physics qualification test as the research object. Firstly, based on the research of literature and investigation, this paper puts forward ten hypotheses that influence the difficulty of multiple choice questions in the physics qualifying examination. In this study, a feasible and valid test difficulty assessment tool was developed. This tool was used to analyze 108 single-choice questions of the high school physics qualifying examination in Guangxi from 2014 to 2019.

Combining statistical methods such as partial correlation analysis and non-parametric mean rank test for statistical testing and quantitative analysis, five factors that are closely related to the difficulty of multiple-choice questions are obtained. Finally, the method of multiple stepwise regression was used to obtain the prediction model of the difficulty coefficient  $P$  of the multiple choice questions of the physics qualifying test, and the reliability of the model was tested by using the data of the physics qualification test in 2020. After testing, the prediction effect of the model was good, which also confirmed the data reliability of the analysis.

**Keywords:** qualifying examination; physics test items; affecting factors; estimated difficulty